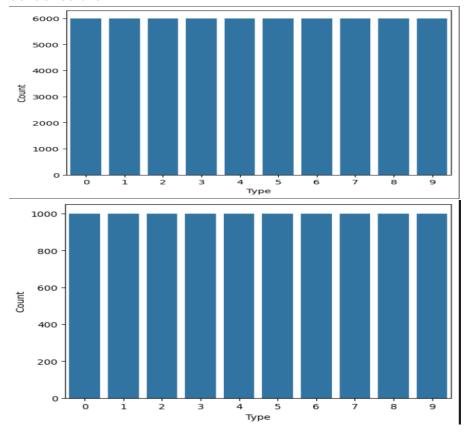
Clasificare de imagini pe baza algoritmilor de invatare automata

Stan Petrișor Cătălin, 342C3

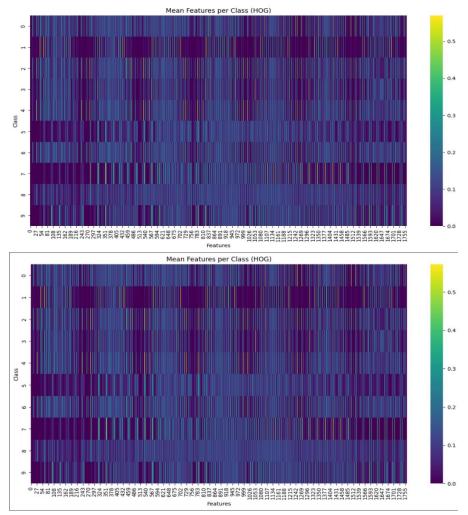
1. Fashion-MNIST EDA

Metode alese pentru extragerea de attribute din imagini:

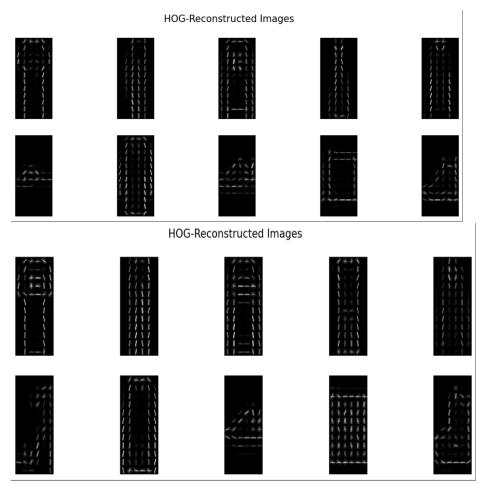
- a. HOG(Histogram of Gradients)
 - Alegere facuta deoarece analiza hainelor nu tine cont de culoarea acestora ci doar de forma lor, HOG fiind un bun candidat pentru determinarea orientarii varfurilor obiectului(ce determina la randul lor forma acestuia).
 - ii. Vizualizarile si statisticile cerute atat pe setul de antrenare cat si pe cel de testare:



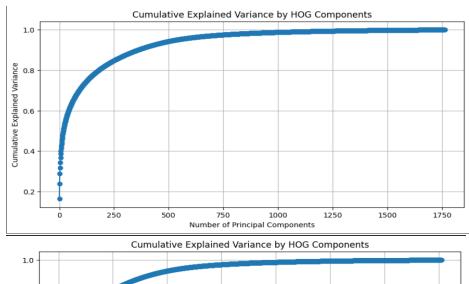
iii. Putem observa un echilibru al claselor atat pe setul de antrenare cat si pe cel de testare, acestea fiind distribuite in mod egal.

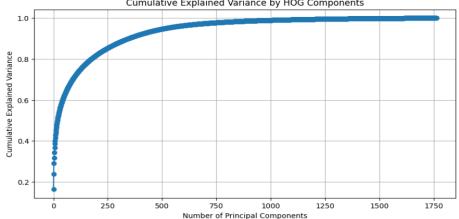


iv. Culoarea mov inchisa din heatmap-urile de mai sus(pentru fiecare clasa in parte) reprezinta atributele relevante ale unei imagini, ce dau de fapt forma si orientarea acestuia, pe cand culori foarte deschise de albastru(sau cele de galben) reprezinta atributele mai putin importante din imagine.



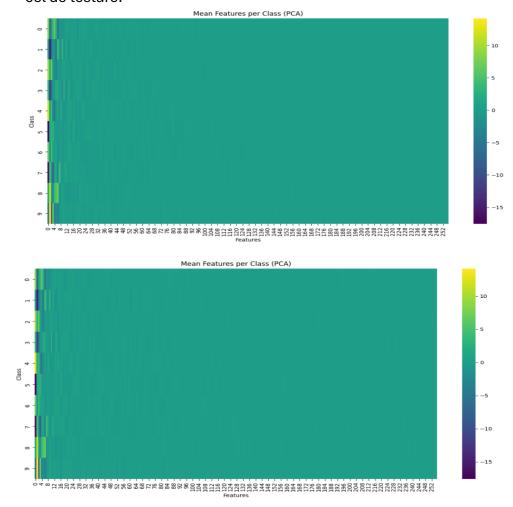
v. Mai sus se pot observa imaginile reconstruite. Acestea sunt de conturate datorita numarului mare de atribute obtinute in urma extragerii(am dat "resize" la imagini facandu-le de 64x64).





- vi. In aceste 2 grafice am analizat varianta cumulativa per numarul de atribute ale imaginii. Initial se observa o crestere rapida a curbei(indicand faptul ca putine atribute dau cea mai mare parte din varianta, adica putine atribute sunt relevante pentru imagine). Dupa ~500 de componente observam contributia din ce in cem ai mica a atributelor adaugate, acestea nemaifiind intr-atat de relevante.
- b. PCA(Principal Components Analysis)
 - i. Alegere facuta din cauza simplitatii metodei, alegand sa extrag doar componentele care retin 95% din varianta.

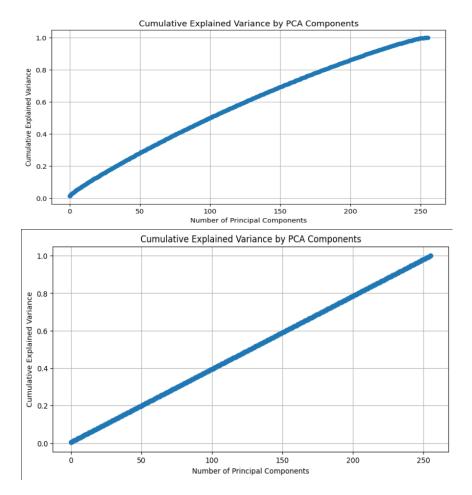
ii. Vizualizarile si statisticile cerute atat pe setul de antrenare cat si pe cel de testare:



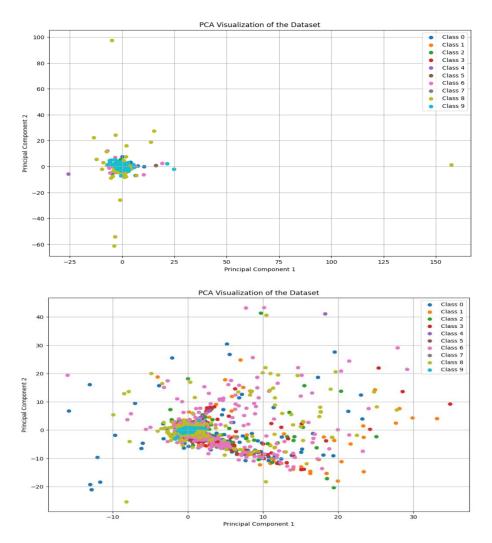
iii. Exact ca la HOG, putem observa si aici o importanta mult mai mare a atributelor extrase. Acest heatmap arata relevanta atributelor extrase cu PCA, o proportie semnificativa dintre ele fiind importante pentru descrierea imaginilor.

PCA-Reconstructed Images PCA-Reconstructed Images PCA-Reconstructed Images PCA-Reconstructed Images

iv. Aici putem observa imaginile reconstruite folosind cele 256 de componente extrase.



v. Se poate explica in aceste ilustratii o crestere mai lenta a variantiei cumulative in raport cu numarul de atribute extrase, deoarece cum am observant si in heatmap-ul de mai sus, toate componentele sunt relevante imaginii.



vi. Aceste 2 grafice arata suprapunerea semnificativa a claselor, cee ace sugereaza ca acestea sunt greu de separate utilizandu-se doar un spatiu bidimensional(trebuia facuta o diagrama 3D aici pentru o vizualizare mai concisa).

Data Preprocessing

Am ales pentru standardizarea datelor **StandardScaler**, iar pentru selectia atributelor am utilizat **SelectPercentile** cu parametrul **percentile** avand valoarea 10. Setul initial de date(cel obtinut in uma aplicarii metodelor de extractie prezentate anterior) difera de setul de date obtinut dupa selectie prin numarul de atribute alese, dar totusi se aseamana prin relevanta datelor ramase, **SelectPercentile** selectand cele mai puternice 10% atribute din cele initiale.

Models Training and Performance Counters

Algoritmii de Invatare Automata utilizati au prezentat urmatoarele performante:

a. Logistic Regression

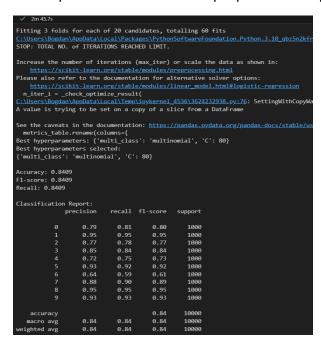
1. Timp executie: 165.7 secunde

2. Rezultate pentru combinatii de hiperparametrii:

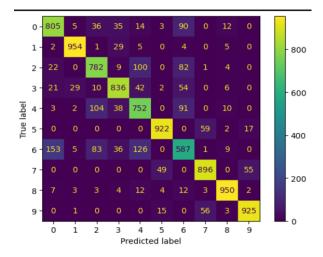
						F1-
		Accuracy	Accuracy	Precision	Recall	Score
param_C	param_multi_class	(mean)	(std)	(mean)	(mean)	(mean)
10	ovr	0.844	0.001	0.841	0.844	0.842
10	multinomial	0.845	0	0.844	0.845	0.844
20	ovr	0.844	0.001	0.841	0.844	0.842
20	multinomial	0.845	0.001	0.843	0.845	0.844
30	ovr	0.844	0.001	0.841	0.844	0.842
30	multinomial	0.845	0.001	0.844	0.845	0.844
40	ovr	0.844	0.001	0.841	0.844	0.842
40	multinomial	0.845	0.001	0.843	0.845	0.844
50	ovr	0.844	0.001	0.841	0.844	0.842
50	multinomial	0.844	0.001	0.843	0.844	0.843
60	ovr	0.844	0.001	0.841	0.844	0.842
60	multinomial	0.845	0.001	0.844	0.845	0.844
70	ovr	0.843	0.001	0.841	0.843	0.842
70	multinomial	0.845	0.001	0.844	0.845	0.844
80	ovr	0.843	0.001	0.841	0.843	0.842
80	multinomial	0.845	0.001	0.844	0.845	0.844
90	ovr	0.843	0.001	0.841	0.843	0.842
90	multinomial	0.844	0.001	0.843	0.844	0.844
100	ovr	0.843	0.001	0.841	0.843	0.841
100	multinomial	0.845	0.001	0.844	0.845	0.844

Observam ca toate combinatiile de forma (C, **multinomial**) obtin performante mai bune in clasificare comparative cu cele ce folosesc **ovr.**

3. Raport de clasificare si hiperparametrii optimi determinati:



4. Matrice de confuzie obtinuta:



Pe baza raportului de clasificare si a matricei de confuzie obtinuta se pot observa clasele cu cele mai bune predictii: **Trouser**(1), **Sandal**(5), **Bag(8)**, **Ankle Boot**(9). Celelalte clase prezinta o acuratete la fel de buna aproape, exceptie facand clasa **Shirt**(6) unde se poate observa confuzia facuta cu clasele **T-shirt**, **Pullover** si **Coat**, acestea avand valori similare atributelor dupa cum se poate observa in urma extragerii atributelor cu **HOG**.

b. SVM

1. Timp executie: 2177.4 secunde

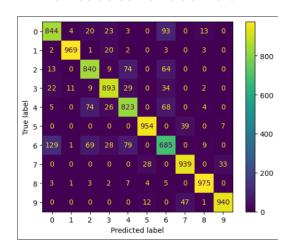
2. Rezultate pentru combinatii de hiperparametrii:

						F1-
		Accuracy	Accuracy	Precision	Recall	Score
param_C	param_kernel	(mean)	(std)	(mean)	(mean)	(mean)
10	rbf	0.886	0.002	0.886	0.886	0.886
10	poly	0.883	0.002	0.883	0.883	0.883
20	rbf	0.886	0.002	0.885	0.886	0.885
20	poly	0.881	0.002	0.881	0.881	0.881
30	rbf	0.884	0.002	0.883	0.884	0.884
30	poly	0.88	0.003	0.88	0.88	0.88
40	rbf	0.883	0.002	0.882	0.883	0.882
40	poly	0.878	0.004	0.879	0.878	0.879
50	rbf	0.882	0.002	0.882	0.882	0.882
50	poly	0.878	0.003	0.878	0.878	0.878

Combinatiile de hiperparametrii ce contin **rbf** obtin performante mai bune comparativ cu restul cum se poate observa din tabel.

3. Raport de clasificare si hiperparametrii optimi determinati:

```
CillyeralBoadenAonDatallocallPackages1PythonSoftwareFoundation_Pywarnings.warn(
Fitting 3 folds for each of 10 candidates, totalling 30 fits Best hyperprimemters; ('kernal': 'rbr', 'C': 30) fits Best hyperprimemters; ('kernal': 'rbr', 'C': 30) fits Statistical Communication of the Statistical Com
```



Se poate observa o performanta mai buna a predictiilor, clasa **Sneaker**(7) avand acuratete mai mare comparative cu metodei de regresie logistica.

c. Random Forest

1. Timp executie: 445.6 secunde

2. Rezultate pentru combinatii de hiperparametrii:

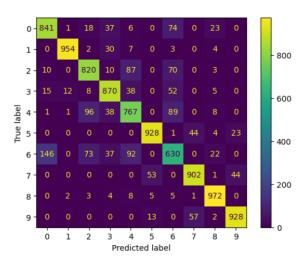
							F1-
			Accura		Precisi	Recall	Score
param_n_estima	param_max_de	param_max_sam	су	Accura	on	(mea	(mea
tors	pth	ples	(mean)	cy (std)	(mean)	n)	n)
150	100	0.7	0.861	0.002	0.86	0.861	0.86
50	50	0.5	0.855	0.002	0.854	0.855	0.854
100	100	0.5	0.857	0.003	0.856	0.857	0.856
100	100	0.6	0.859	0.002	0.858	0.859	0.858
10	50	0.6	0.83	0.002	0.829	0.83	0.829
150	100	0.6	0.86	0.002	0.859	0.86	0.859
50	50	0.7	0.857	0.001	0.856	0.857	0.856
10	50	0.5	0.828	0.001	0.827	0.828	0.827
10	10	0.7	0.825	0.002	0.824	0.825	0.824
50	50	0.6	0.856	0.002	0.855	0.856	0.855
50	10	0.7	0.835	0.001	0.834	0.835	0.834
100	100	0.7	0.86	0.001	0.859	0.86	0.859
10	10	0.5	0.822	0.003	0.822	0.822	0.822
10	10	0.6	0.822	0.002	0.822	0.822	0.821
50	100	0.6	0.856	0.002	0.855	0.856	0.855
150	50	0.5	0.858	0.002	0.857	0.858	0.857
150	50	0.6	0.86	0.002	0.859	0.86	0.859
50	10	0.6	0.835	0.002	0.834	0.835	0.834
150	10	0.7	0.838	0.001	0.837	0.838	0.837
50	10	0.5	0.836	0	0.835	0.836	0.835

Se poate observa ca numarul de arbori utilizati pentru predictie afecteaza cel mai mult performanta si rezultatele obtinute.

3. Raport de clasificare si hiperparametrii optimi determinati:

```
Fitting 3 folds for each of 20 candidates, totalling 60 fits Best hyperparameters: {'n_estimators': 150, 'max_samples': 0 C:\Users\Bogdan\AppData\Local\Temp\ipykernel_4536\3624232938
A value is trying to be set on a copy of a slice from a Data
See the caveats in the documentation: <a href="https://pandas.pydata">https://pandas.pydata</a>
  metrics_table.rename(columns={
Best hyperparameters selected:
{'n_estimators': 150, 'max_samples': 0.7, 'max_depth': 100}
Accuracy: 0.8612
Recall: 0.8612
Classification Report:
                                   recall f1-score
                                                            support
                                      0.84
                                     0.95
0.82
                                                                1000
                        0.80
                                                   0.81
                                                                1000
                                                                1000
                                                                1000
                        0.93
                                      0.93
                                                   0.93
                                                                1000
                        0.68
                                      0.63
                                                   0.65
                                                                1000
                                                                1000
                        0.93
                                      0.97
                                                   0.95
                                                                1000
                        0.93
                                      0.93
                                                   0.93
                                                                1000
     accuracy
                                                   0.86
                                                               10000
                        0.86
                                      0.86
                                                               10000
    macro avg
                                                   0.86
  eighted avg
```

4. Matrice de confuzie obtinuta:



Performanta obtinuta este mai slaba comparativ cu **SVM**, dar mai buna raportandu-ne la **Logistic Regression**.

d. Gradient Boosted Trees

- 1. Timp executie: 829.7 secunde
- 2. Rezultate pentru combinatii de hiperparametrii:

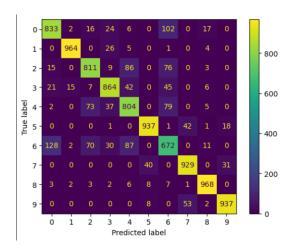
							F1-
			Accura		Precisi	Recall	Score
param_n_estima	param_max_de	param_learning_	су	Accura	on	(mean	(mean
tors	pth	rate	(mean)	cy (std)	(mean)))
150	7	0.01	0.847	0.003	0.845	0.847	0.845
100	5	0.05	0.856	0.002	0.855	0.856	0.855
50	3	0.05	0.811	0.004	0.809	0.811	0.809
50	5	0.1	0.855	0.002	0.854	0.855	0.854
50	3	0.01	0.764	0.001	0.764	0.764	0.762
150	3	0.05	0.843	0.002	0.842	0.843	0.842
100	7	0.05	0.866	0.002	0.865	0.866	0.866
150	7	0.05	0.872	0.002	0.872	0.872	0.872
50	5	0.05	0.84	0.003	0.839	0.84	0.839
50	7	0.1	0.866	0.003	0.865	0.866	0.865
100	3	0.01	0.784	0.002	0.782	0.784	0.782
100	5	0.01	0.823	0.004	0.821	0.823	0.821
150	5	0.01	0.83	0.003	0.828	0.83	0.828
150	3	0.01	0.796	0.003	0.794	0.796	0.794
50	7	0.05	0.854	0.002	0.853	0.854	0.853
100	5	0.1	0.869	0.002	0.868	0.869	0.868
50	5	0.01	0.812	0.005	0.81	0.812	0.81
100	7	0.1	0.876	0.002	0.875	0.876	0.875
150	5	0.1	0.876	0.002	0.876	0.876	0.876
50	3	0.1	0.831	0.004	0.829	0.831	0.83

Se observa ca numarul de arbori si adancimea acestora afecteaza cel mai mult metricile obtinute.

3. Raport de clasificare si hiperparametrii optimi determinati:

```
Fitting 3 folds for each of 20 candidates, totalling 60 fits
Best hyperparameters: {'n_estimators': 150, 'max_depth': 5, 'learning_rate': 0.1}
Best hyperparameters selected:
{'n_estimators': 150, 'max_depth': 5, 'learning_rate': 0.1}
Accuracy: 0.8719
F1-score: 0.8719
Recall: 0.8719
Classification Report:
                                                                           0.83
0.97
0.82
0.87
                                      0.83
0.98
                                                           0.83
0.96
                                                            0.81
0.86
0.80
                                                                                                        1000
1000
1000
                                                                                 0.94
0.68
                                       0.94
0.68
                                                             0.94
0.67
                                                                                                        1000
1000
                                                                                 0.92
0.96
0.94
                                       0.95
0.95
                                                            0.97
0.94
                                                                                                        1000
1000
   macro avg
```

4. Matrice de confuzie obtinuta:

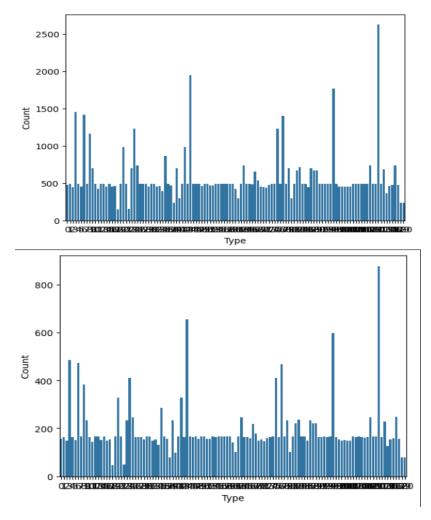


In afara de **SVM**, se pot observa cele mai bune performante pentru acest algoritm.

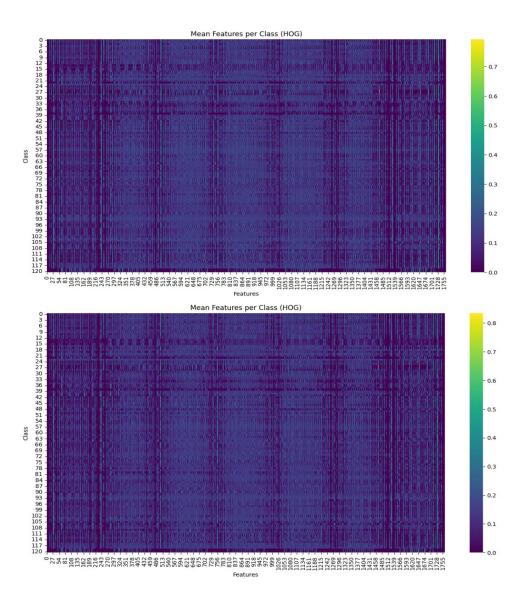
2. Fruits-360 EDA

Metode alese pentru extragerea de attribute din imagini:

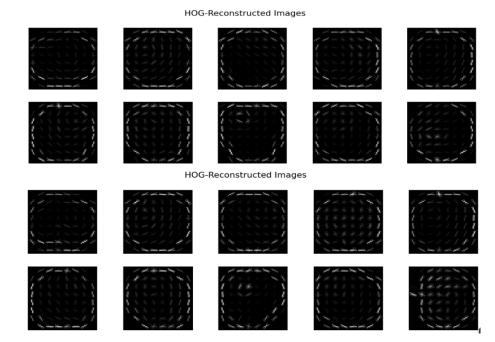
- a. HOG(Histogram of Gradients)
 - i. Alegere strict bazata in acest caz pe simplitatea metodei
 - ii. Vizualizarile si statisticile cerute atat pe setul de antrenare cat si pe cel de testare:



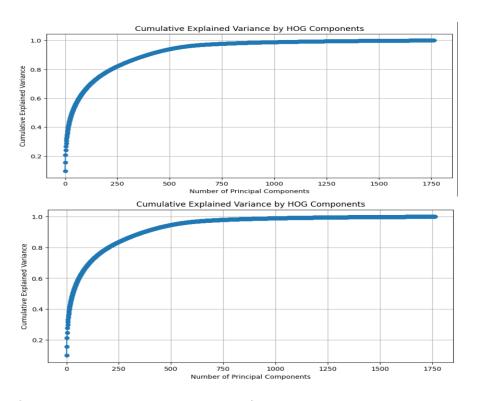
Observam un dezechilibru pentru anumite clase. In total am extras 121 de clase din cele 141 de directoare puse la dispozitie pentru setul de antrenare.



Atributele extrase pentru fiecare clasa in parte nu sunt tocmai cele mai relevante in urma utilizarii **HOG**, deoarece in cazul fructelor se tine cont si de culoarea acestora, dar **HOG** nu retine informatii legate de culoare.

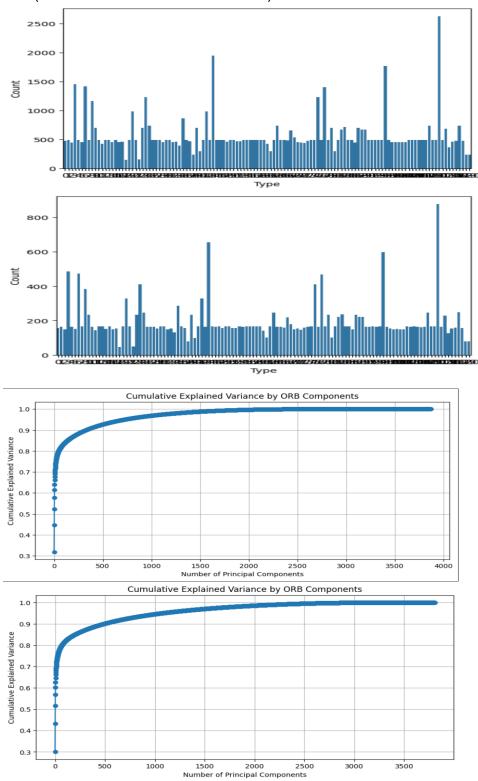


Imaginile reconstruite prezinta similaritati mari, datorita formei fructelor.

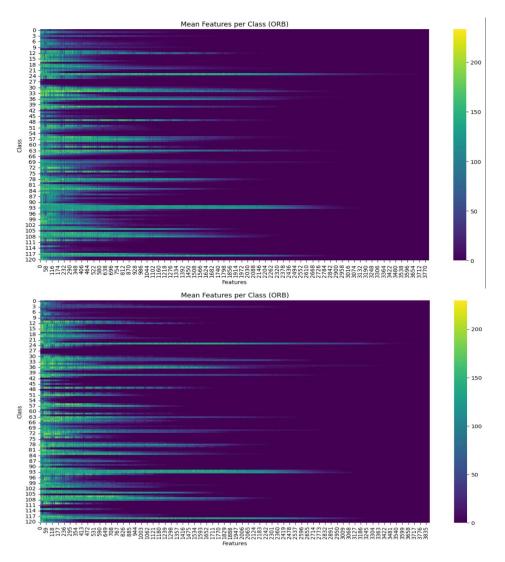


Se observa, exact ca la setul anterior de date, ca aceasta metoda necesita ~500 de atribute pentru varianta ridicata.

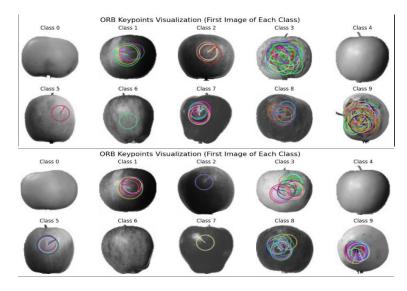
b. ORB(Oriented FAST and Rotated BRIEF)



Comparativ cu **HOG**, aici putem observa o crestere mai rapida(dar pentru mai multe atribute).



Se poate observa din aceste 2 heatmap-uri ca majoritatea atributelor extrase cu **ORB** prezinta relevanta ridicata in raport cu imaginile(**ORB** tine cont atat de forma obiectului cat si de culoarea acestuia).



Imaginile reconstruite in urma utilizarii ORB.

Data Preprocessing

Metode similare cu cele utilizate la setul de date anterior au fost folosite si aici.

Models Training and Performance Counters

a. Logistic Regression

1. Timp executie: 541.4 secunde

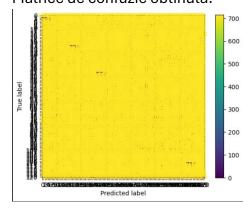
2. Rezultate pentru combinatii de hiperparametrii:

						F1-
		Accuracy	Accuracy	Precision	Recall	Score
param_C	param_multi_class	(mean)	(std)	(mean)	(mean)	(mean)
10	ovr	0.394	0.055	0.442	0.422	0.415
10	multinomial	0.415	0.052	0.444	0.448	0.432
20	ovr	0.391	0.053	0.441	0.419	0.413
20	multinomial	0.414	0.052	0.442	0.447	0.431
30	ovr	0.39	0.054	0.442	0.418	0.413
30	multinomial	0.414	0.052	0.442	0.446	0.43
40	ovr	0.389	0.054	0.441	0.417	0.412
40	multinomial	0.413	0.051	0.441	0.445	0.429
50	ovr	0.39	0.055	0.442	0.418	0.412
50	multinomial	0.412	0.051	0.44	0.445	0.428

Se observa rezultate slabe in momentul utilizarii acestui algoritm din cauza utilizarii metodei **HOG** de extragere a atributelor(metoda ce nu tine cont si de culoarea fructelor).

3. Raport de clasificare si hiperparametrii optimi determinati:

Rezultatele generale de clasificare au fost mai bune fata de cele obtinute in tabelul prezentat anterior(probabil si pentru ca nu sunt visible toate clasele din raport).



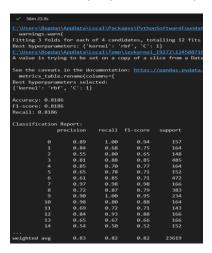
b. SVM

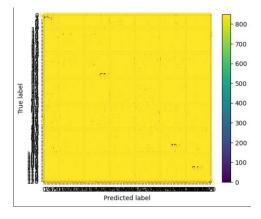
1. Timp executie: 3503.9 secunde

2. Rezultate pentru combinatii de hiperparametrii:

						F1-
		Accuracy	Accuracy	Precision	Recall	Score
param_C	param_kernel	(mean)	(std)	(mean)	(mean)	(mean)
0.1	rbf	0.414	0.093	0.481	0.422	0.416
0.1	poly	0.314	0.065	0.444	0.312	0.324
1	rbf	0.521	0.06	0.582	0.557	0.543
1	poly	0.456	0.071	0.566	0.486	0.481

3. Raport de clasificare si hiperparametrii optimi determinati:





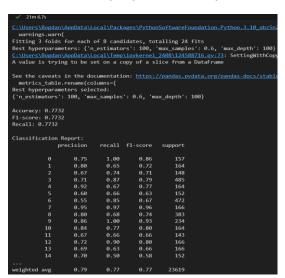
c. Random Forest

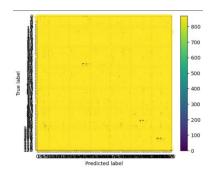
1. Timp executie: 1266.7 secunde

2. Rezultate pentru combinatii de hiperparametrii:

							F1-
			Accura		Precisi	Recall	Score
param_n_estima	param_max_de	param_max_sam	су	Accura	on	(mea	(mea
tors	pth	ples	(mean)	cy (std)	(mean)	n)	n)
50	50	0.6	0.489	0.07	0.527	0.514	0.498
100	50	0.6	0.512	0.069	0.559	0.536	0.522
50	50	0.7	0.491	0.07	0.532	0.516	0.501
100	50	0.7	0.511	0.069	0.563	0.536	0.523
50	100	0.6	0.489	0.07	0.527	0.514	0.498
100	100	0.6	0.513	0.069	0.559	0.537	0.523
50	100	0.7	0.492	0.07	0.532	0.516	0.501
100	100	0.7	0.512	0.068	0.564	0.537	0.524

3. Raport de clasificare si hiperparametrii optimi determinati:





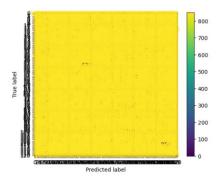
d. Gradient Boosted Trees

1. Timp executie: 3341.3

2. Rezultate pentru combinatii de hiperparametrii:

							F1-
			Accura		Precisi	Recall	Score
param_n_estima	param_max_de	param_learning_	су	Accura	on	(mean	(mean
tors	pth	rate	(mean)	cy (std)	(mean)))
50	5	0.05	0.39	0.06	0.452	0.409	0.408
100	5	0.05	0.425	0.062	0.491	0.445	0.445
50	7	0.05	0.403	0.061	0.458	0.424	0.422
100	7	0.05	0.436	0.061	0.491	0.458	0.454
50	5	0.1	0.416	0.058	0.474	0.438	0.436
100	5	0.1	0.457	0.059	0.514	0.48	0.476
50	7	0.1	0.421	0.059	0.47	0.445	0.44
100	7	0.1	0.457	0.059	0.502	0.483	0.474

3. Raport de clasificare si hiperparametrii optimi determinati:



Concluzii

Rezultatele obtinute pe cele 2 seturi de date difera raportandu-ne la metricile obtinute, acestea depinzand de natura imaginilor si a distributiei lor. Cele mai bune rezultate au fost obtinute pe setul de date Fashion-MNIST datorita metodei de extragere utilizata(HOG) ce a determinat definirea formei hainelor prin care au fost extrase atribute relevante ce au ajutat la clasificare. Pe setul de date Fruits-360 au fost obtinute rezultate mai putin precise datorita utilizarii aceleasi metode de extragere (am incercat sa utilizez ORB in continuare, dar era obtinuta o acuratete foarte scazuta, de ~15-20%). O alta caracteristica importanta in procesul de clasificare a fost timpul de executie pentru determinarea hiperparametrilor optimi. Cu cat numarul de combinatii de hiperparametrii era mai ridicat, cu atat timpul de executie era mai mare, situatie ce necesita multe resurse ale sistemului(era de preferat sa se ruleze pe un cluster tema sincer, nu aveam destul RAM in unele momente sa rulez). In acelasi timp pentru obtinerea unor performante mai mari ar fi trebuit selectate mai multe atribute in urma extragerii si a preprocesarii datelor. S-au ales 10% cele mai bune de fiecare data, utilizand metoda SelectPercentile(problema este ca daca numarul de atribute selectate era mai mare, timpul de executie era la randul lui mai mare, dar am observat pentru 20% atribute selectate o performanta mai buna a metricilor utilizate).

Observatii

Tema a fost interesanta, ajutandu-ma sa capat cunostiinte noi(cum ar fi selectia de atribute din imagini si partea de cautare a hiperparametrilor optimi), cat si sa ma deprind mai bine cu Python-ul si module si biblioteci populare din acesta.